Автоматический выбор временных признаков и обучаемые представления в рекомендательных системах

KION и Yambda: сильная ручная база, равный бюджет поиска и стоимость запроса

Аннотация. Проверяется ограниченная автоматизация временных признаков поверх сильного двухуровневого рекомендателя. На KION все ранжировщики получают общий union кандидатов; дополнительные окна дополняют ручную базу, а компактные ALS-признаки и якоря проверяют другую гипотезу - частичную замену агрегатов. У выбранных окон итоговый NDCG@10 равен 0.165822 против 0.163488 у manual; календарная неделя ранее изучалась на других пользователях. Позднее добавлен контроль четырёх случайных наборов окон при том же условном бюджете четырёх обучений: его лучший development NDCG ниже importance-процедуры на 0.001330. Внешняя проверка на Yambda использует новые когорты и три заранее заданные недели: importance-отбор относительно manual даёт ΔNDCG +0.000726, пользовательский 95% интервал [-0.002946; +0.004308]. Интервал включает ноль; две недельные разности отрицательны. Отдельный warm-state benchmark 128 пользователей измеряет 2.323/2.361 с на запрос manual/выбранных окон при трёх seed-моделях в обеих ветвях. Представления не заменили сильную ручную базу; инвариантность якорей сама по себе не обеспечила устойчивого прироста. Выводы ограничены наблюдаемыми откликами, fixed candidate retrieval и заданными периодами; онлайн-эффект и универсальное превосходство не заявляются.

Ключевые слова: рекомендательные системы; временные признаки; random search; KION; Yambda; стоимость inference.

Отдельный исторический результат KION. Исходная смесь шести моделей против трёх у manual: ΔNDCG +0.001512; 95% пользовательский bootstrap: [-0.000040; +0.003091]. Интервал включает ноль; дополнительная стоимость не превращается в установленную пользу, и после теста смесь не пересматривается.

1. Исследовательский вопрос

Промышленный рекомендатель редко выбирает между статистикой и машинным обучением как между двумя независимыми подходами. Часто несколько моделей формируют кандидатов, а бустинг объединяет их оценки с временными, категориальными и пользовательскими признаками. Поэтому полезный вопрос состоит в том, какие части такой системы можно автоматизировать без потери качества и какие дополнительные ресурсы для этого требуются.

Мы разделяем три гипотезы: дополнительные временные окна могут улучшить сильную базу; компактные признаки представлений могут заменить часть ручных агрегатов; геометрия относительно фиксированных объектов может дополнить скалярную близость latent-факторов. Эти гипотезы неэквивалентны: успешное дополнение ручной базы само по себе не означает успешной замены, а улучшение выбранной смеси не приписывается одному признаку. Контроль случайного поиска проверяет полезность importance-эвристики при ограниченном бюджете, а Yambda - перенос этой постановки на другой домен и несколько периодов, без переноса movie-specific длительности.

2. Связь с опубликованными решениями

Многогенераторная схема опирается на открытый разбор решения Т-Банка для Rekko [1]: collaborative retrieval и его score/rank используются на втором уровне. Перенесён архитектурный приём, а не весь конкурсный ансамбль. Настройки WARP и BM25 адаптированы к данным и ограничениям эксперимента; опубликованный конкурсный результат не служит оценкой нашей системы.

Описание KION [2] важно не только как источник benchmark, но и как определение наблюдений: строка пары содержит последнюю дату и накопленные характеристики просмотра. Из решения Д. Тихонович [3] перенесены CatBoost-классификация, статистики дат и тренд после сглаживания Hamming7. Из открытого решения А. Петрова [4] использованы идеи демографической популярности, последних объектов и связей между историей и кандидатом. Наши временные срезы, широкий union и сравнение семейств зафиксированы отдельно, поэтому работа не заявляет полного воспроизведения победителей.

RecTools [5] задаёт конкретный weighted iALS-рецепт: фильтр длительности, веса confidence и совместное использование метаданных. В системе присутствуют также WARP/LightFM [6] и EASE [7]. EASE ограничен наиболее популярной частью prefix-каталога: это осознанная ресурсная адаптация линейного метода, а не обучение на полном каталоге.

FeatAug [8] рассматривает predicate-aware агрегаты по отношениям one-to-many и поиск запросов. У нас временной интервал играет роль предиката, а связь с категорией кандидата - роль условной агрегации. Однако SQL-движок, Bayesian optimization/TPE и beam search FeatAug не реализованы. Используется небольшая заранее материализованная грамматика и перебор префиксов групп. Featuretools [9] служит ориентиром для cutoff-aware определения признаков, но DFS также не запускается.

ProtoMF [10] мотивирует описание предпочтений через опорные направления. Наши anchors - реальные объекты, выбранные после обучения ALS, а не совместно обучаемые прототипы; prototype objective не воспроизводится. Это также не Nyström-аппроксимация: отсутствуют whitening и восстановление полного ядра. Идея ограничивается удобным для дерева представлением геометрии.

Что не проверяется

Современные последовательные и экосистемные представления, включая Perseus, требуют другого набора событий и постановки. Здесь не обучались Transformer/SASRec и текстовый item encoder. Неполная последовательность последних взаимодействий KION не подменяет полный журнал просмотров. Поэтому результаты ALS-признаков не являются проверкой всех методов representation learning.

Практический вклад работы - согласованное сравнение этих ограниченных конструкций на общей выдаче кандидатов с прозрачной ценой в признаках, деревьях и числе моделей. Конкурентоспособность оценивается по собственным данным; авторитет исходного рецепта не трактуется как доказательство прироста.

3. Данные, наблюдения и временной протокол

Используется KION: 5 476 251 строка, 962 179 пользователей и 15 706 объектов во взаимодействиях (15 963 в таблице каталога); даты в использованной выгрузке с 13 марта по 22 августа 2021 года. Наблюдение представляет уникальную пару user-item. Показов, достоверных отрицательных откликов и полной последовательности повторных просмотров нет. Релевантность в основном эксперименте бинарна и не зависит от будущей длительности целевой строки.

$$H(t) = \{ (u,i,\tau,\ldots) : \tau < t \}; \; Y_{u,t} = \{ i : t \le \tau_{ui} < t + 7 \text{ суток} \}.$$

Все признаки и генераторы используют строгий прошлый префикс H(t). Доступный каталог содержит объекты, встречавшиеся до t; seen-пары пользователя исключаются. Положительные объекты вне каталога или retrieval union не удаляются из знаменателей метрик. Таким образом, ranker не получает принудительно добавленных правильных ответов.

Таблица 1. Семидневные интервалы 2021 года и размеры случайных когорт.

Роль	Начало прогноза	Конец интервала	Пользователей
Обучение	19, 26 июля	26 июля, 2 августа	100000
Validation	2, 9 августа	9, 16 августа	15000
Confirmation	16 августа	23 августа	40000

Пользовательские когорты попарно не пересекаются; выбор выполняется без фильтра по будущей активности, seed 736291. Истории сохраняются целиком. Глобальные collaborative-модели и агрегаты используют весь доступный префикс, включая прошлые истории итоговых пользователей. Это трансдуктивный протокол: отсутствие пользователя в supervised-fit второго уровня не означает отсутствия его прошлого в retrieval.

Из итоговой когорты исключены 10 992 пользователя, чьи результаты просматривались в ранних экспериментах. При этом сама календарная неделя 16-23 августа уже исследовалась. Мы называем результат подтверждением на новых пользователях знакомого периода, а не полностью нетронутым временным holdout. Общие календарные тренды и каталог создают зависимость между пользователями.

Основная оценка условна на наличии прошлой истории и хотя бы одного будущего positive. Будущая активность задаёт только множество оцениваемых запросов; она не обучает генераторы и не расширяет каталог. Отдельно приводится оценка всех будущих активных пользователей с единым popularity fallback для не имеющих истории. Отсутствующие будущие positives не позволяют определить обычный пользовательский Recall; удержание всей исходной когорты здесь не измеряется.

4. Общие кандидаты и обучающая выборка

$$C_{u,t} = Union_g\ TopK_g(u,H(t)),\ без\ Seen_{u,t}.$$

$$Recall_u@10 = |Top10_u \cap Y_u| / |Y_u|;$$
$$NDCG_u@10 = [\Sigma_{k=1,\dots,10}\ rel_{u,k}/log_2(k+1)] / IDCG_u@10.$$

В ideal DCG положительны первые min(10, $|Y_u|$) позиций. Все пользовательские метрики усредняются с равными весами; missing positives уменьшают достижимую оценку.

Каждая feature-ветвь получает одинаковые user-item строки и одинаковый каталог. Бюджеты источников фиксируются до оценки ранжировщиков. Перекрывающиеся выдачи объединяются без дубликатов. Отсутствие кандидата является ошибкой retrieval; последующее ранжирование не может её исправить. Наряду с предметными признаками передаются scores и ranks генераторов.

Таблица 2. Общий многогенераторный union. Нулевой budget ALS96 не означает отсутствие его признаков.

Источник	Бюджет на пользователя	Основная настройка
BM25; RP3beta	100; 100	top-K 200; RP3 α=1, β=0.6
WARP; EASE; popularity	500; 500; 500	WARP 128D/20 эпох; EASE λ=1000
Sex/age/income/kids popularity	По 60	Условная популярность
Binary bias/hybrid ALS	По 50	Отдельные источники
Weighted bias/hybrid ALS	По 100	bias128 и metadata32
ALS96	0	Оценки доступны как признаки

EASE обучается на 5000 наиболее популярных объектов префикса, а не на полном каталоге. Это ограничивает охват его собственного источника, но не удаляет объекты из остальных источников или из истинных ответов. Широкий union включает и глобально популярные, и персональные объекты.

Сэмплирование для второго уровня

$$n_{neg}(q) = min(3\ n_{pos}(q),\ 25,\ n_{available}(q)).$$

Для каждого train-запроса сохраняются все найденные positives и случайные negatives без возвращения по указанному правилу. Запрос без найденного positive пропускается только при обучении второго уровня. CatBoost и LightGBM используют один и тот же sampled pool. Негативы выбираются непосредственно из полного union; отдельного предшествующего hard-negative поднабора нет. На validation и confirmation ранжируются полные candidate lists.

Ненаблюдаемая пара не означает доказанное отсутствие интереса: пользователь мог не видеть объект. Negative sampling и class weights меняют распределение обучающих примеров, поэтому выход классификатора используется только как ranking score. Ни калиброванная вероятность клика, ни catalogue-wide LogLoss не заявляются. После выбора рецепта к train добавляются сэмплированные validation-запросы; недельные query IDs остаются разными.

Сохранённый анализ validation union даёт около 933.7 кандидата на пользователя и macro candidate recall 0.8004 при равном весе недель. Oracle NDCG@10 равен примерно 0.8305: это недостижимая без меток сортировка найденных positives первыми, а не качество обученной модели. Удаление источника из union измеряет потерю покрытия, но не эффект переобучения ranker.

5. Ручные и автоматически сгенерированные признаки

Manual является сильной базой: категории пользователя и объекта, item identity, scores/ranks общих генераторов, характеристики последних пяти объектов и сходства с ними, ручные временные агрегаты и свойства завершённых пар. Добавляются median/std дат, сглаженный Hamming7-тренд, доли наиболее недавних строк и частоты категорий prefix-каталога. Это промышленно мотивированная архитектура второго уровня, но не утверждение о готовности всей системы к production SLA.

$$N_{u,w}(t) = \Sigma_{e \text{ in } H(t)} \, 1[u_e = u] \, 1[t - w \le \tau_e < t],$$
$$Share_{u,w} = N_{u,w} / max(N_{u,all}, 1).$$

Аналогично считаются item counts и shares. Ручная база использует окна 1/7/30 дней и всю историю. Дополнительная грамматика материализует окна 2/3/5/10/14/21/45/60/90 дней. Единица наблюдения здесь - сохранённая пара с последней датой, а не каждый просмотр фильма. Такое различие особенно важно для интерпретации коротких окон.

Пусть $X^{(w)}$ - sparse user-item матрица прошлого окна, A^r - бинарная item-token матрица отношения r, например жанра или страны. Профиль и affinity задаются как

$$P^{r,w} = X^{(w)} A^r;$$
$$Affinity_{u,i}^{r,w} = P_u^{r,w} (A_i^r)^T.$$

Нормированная affinity делится на max(сумма token-counts профиля,1). Совпадение нескольких категорий даёт несколько вкладов: это не просто индикатор наличия хотя бы одного общего жанра. Отношения и операторы заранее заданы; алгоритм не изобретает произвольные формулы или связи.

Характеристики завершённых пар

Для last_watch_dt < cutoff все просмотры, вошедшие в сохранённую строку, лежат в прошлом. Поэтому исторические total_dur и watched_pct допустимы при принятой семантике дат benchmark. Count/share qualified-пар использует total_dur ≥ 300; также считаются средние log(1+duration), pct и доля сильных пар с pct > 10. Длительность строки, выбранной по недавней последней дате, не является длительностью только внутри окна. Будущую строку нельзя частично восстановить для прошлого.

Групповой выбор окон

Train-fitted CatBoost выбранной development-конфигурации задаёт importance-порядок групп. Затем validation выбирает лучший непустой префикс длиной 1/2/3/5; manual сохраняется всегда. В случае равенства остаётся первый, меньший префикс. Это ограниченная автоматизация выбора окон, а не минимизация числа признаков и не общий AutoML по всем формулам. Отдельно проверяется ветвь со всеми окнами, чтобы отбор не подменял сравнение полным набором.

6. Представления и геометрия относительно якорей

Взвешенный ALS применяет строгий временной префикс, затем оставляет строки с duration ≥ 300. Вес наблюдаемой пары равен 3 при pct > 10 и 1 иначе; confidence - α×weight, α=10, а для пропусков confidence равен 1. Регуляризация .5, десять итераций. Сначала модель обучается на активной подматрице; факторы разворачиваются к исходным ID. Пользователь без qualified history получает popularity fallback weighted-префикса, неактивный item - нулевые факторы.

Совместный metadata32-режим использует опубликованный solve-then-restore приём RecTools: свободные и фиксированные координаты решаются совместно, затем metadata-блок восстанавливается. Это не точная constrained-минимизация. Отдельный bias128-режим добавляет paired-факторы к константам и даёт latent dot плюс user/item bias. Raw labels, seen и каталог при этом не фильтруются по длительности: фильтр меняет источник сигнала, а не задачу оценки.

Произвольные координаты факторов могут вращаться между prefix-fit. Вместо них базовые representation-признаки описывают dot/cosine/norm, скалярные вклады фиксированных semantic metadata-блоков и active-флаги. Ветка representations сохраняет metadata, часть retrieval и history similarity; она заменяет ручные агрегаты, но не является чистой моделью эмбеддингов.

Фиксированные item anchors

На первом train-префиксе 19 июля выбираются до 16 активных ненулевых item-факторов. Pool - первые 1000 по 30-дневной raw-популярности; равенства разрешаются ID. Первый anchor самый популярный, следующие максимизируют минимальное cosine-расстояние до выбранных. Поздние префиксы используют те же ID и свои текущие факторы без повторного отбора.

$$d_j = u\, a_j^T;\ c_j^u = cos(u,a_j);$$
$$c_j^i = cos(v_i,a_j);\ p_j = c_j^u c_j^i.$$

Дополнительный флаг задаёт доступность anchor. При отсутствии или нулевом знаменателе соответствующие величины обнуляются. В joint ALS геометрия использует только свободный latent-блок, без фиксированных metadata. При общем ортогональном Q: $(uQ)(aQ)^T = uQQ^Ta^T = ua^T$, а нормы сохраняются. Следовательно, признаки инвариантны к совместному ортогональному вращению одной модели.

Это не выравнивает независимо обученные prefix-пространства. Шестнадцать направлений в 32D оставляют nullspace размерности 16. Train-диагностика даёт effective rank около 14.585 и 21.88% остаточной энергии raw active item-факторов после проекции на anchor span. Эти числа описывают геометрию, а не качество; 80 дополнительных колонок могут быть избыточны.

7. Обучение, бюджеты и сравниваемые системы

Четыре основные ветви manual/auto_windows/auto_full/representations получают две конфигурации CatBoost и две LightGBM/LambdaRank. CatBoost: depth/L2 = 9/27 либо 7/15, learning rate .03, subsample .97, scale_pos_weight 3, до 2000 деревьев. Каждые 50 деревьев оценивается полный NDCG и выбирается лучший prefix непрерывного обучения. LightGBM проверяет leaves/L2/min_child = 15/.1/80 либо 31/5/100, до 1200 деревьев, learning rate .035, early stopping 100 по той же полной метрике.

Критерий выбора - равное среднее недельных NDCG, а не объединение всех строк двух недель. Это предотвращает доминирование более активного периода, но не создаёт независимой оценки: те же недели используются для HPO, importance-порядка, числа деревьев, feature-prefix и смеси. Development point estimates поэтому имеют оптимизм выбора.

Таблица 3. Выбор на development. Указано число деревьев одной seed-модели.

Ветка	Семейство	Признаки	Деревья	Выбранные параметры
Ручная база	catboost	181	2000	{'depth': 7, 'l2_leaf_reg': 15}
Все окна	catboost	307	1900	{'depth': 7, 'l2_leaf_reg': 15}
Выбранные окна	catboost	223	1950	{'depth': 7, 'l2_leaf_reg': 15}
Представления	catboost	58	1250	{'depth': 9, 'l2_leaf_reg': 27}
Окна + представления	catboost	318	1800	{'depth': 9, 'l2_leaf_reg': 27}
Представления + якоря	catboost	138	1050	{'depth': 9, 'l2_leaf_reg': 27}
Окна + якоря	catboost	398	1800	{'depth': 7, 'l2_leaf_reg': 15}

Бюджеты не полностью одинаковы. Auto_selected перебирает четыре префикса только на CatBoost с настройками, выбранными для auto_windows. Две новые anchor-ветви получают по две прежние CB-конфигурации; отдельной LightGBM-сетки у них нет. Следовательно, best-to-best сравнение характеризует ограниченную процедуру разработки, а не только причинный эффект feature family.

Refit и итоговая смесь

Development использует seed 17. После выбора все варианты переобучаются на train и сэмплированной validation с фиксированным числом деревьев, seeds 17/42/73. Raw scores сначала усредняются внутри каждой ветви. Затем rank-mixture использует ранги полного user candidate list с разрешением score-равенств по item ID.

$$f_b(u,i) = (1/3)\,\Sigma_{s\ in\ \{17,42,73\}} f_{b,s}(u,i);$$
$$S(u,i) = 0.5/(60+r_{windows}) + 0.5/(60+r_{selected}).$$

Выбранная смесь содержит шесть CatBoost-моделей, manual - три. Это не среднее шести индивидуальных рангов и не равный model-count эксперимент. Три seeds не являются тремя независимыми итоговыми выборками. Все семь диагностических вариантов вместе содержат 21 модель; стоимость их общего scoring нельзя выдавать за latency одной выбранной системы.

Материализованный train-pool содержит 151916 пар, полная validation - 3013226; после добавления сэмплированной validation финальный refit использует 178018 обучающих пар. Число строк не равно размеру пользовательской когорты.

8. Development: отбор окон и anchor-диагностика

Таблица 4. Равные веса двух validation-недель. Это метрики после подбора, seed 17.

Ветка	Средний NDCG@10	Средний Recall@10
Ручная база	0.162568	0.233932
Все окна	0.162502	0.237837
Выбранные окна	0.164286	0.239078
Представления	0.150935	0.216338
Окна + представления	0.162987	0.235236
Представления + якоря	0.142835	0.214904
Окна + якоря	0.161961	0.236579

Выбранный префикс дополнительных окон: window_3, window_2, window_5. В этой задаче он дополняет manual. Отбор показывает полезность конкретной ограниченной грамматики и двух development-периодов; он не доказывает оптимальность этих окон для других недель.

Таблица 5. Matched trials: одинаковые family/params/seed; delta = anchor - parent.

База + anchors	Параметры CB	Деревья	ΔNDCG	ΔRecall
Представления	{'depth': 9, 'l2_leaf_reg': 27}	1250 → 1050	-0.008100	-0.001434
Представления	{'depth': 7, 'l2_leaf_reg': 15}	1450 → 1750	-0.005823	-0.003711
Окна + представления	{'depth': 9, 'l2_leaf_reg': 27}	1800 → 2000	-0.001976	-0.002085
Окна + представления	{'depth': 7, 'l2_leaf_reg': 15}	1800 → 1800	+0.001113	+0.000918

Из 4 matched-проб отрицательная NDCG-разность получена в 3. Число деревьев каждая сторона выбирала независимо на validation. Даже совпадение выбранных tree counts в отдельной паре не делает результат независимой повторной проверкой: параметры и точка сравнения рассматриваются после разработки.

Для auto_selected недельные дельты важнее одного среднего. В сохранённом development NDCG-разность относительно manual равна -0.000165 на первой неделе и +0.003601 на второй. Положительное среднее не означает стабильного улучшения в каждом периоде. Финальная смесь не включает anchor-ветви; это результат выбора на validation, а не основание убрать их отрицательные наблюдения из исследования.

Ниже итоговые метрики оценивают refit и ансамбли, а не те же single-seed модели. Изменение development → confirmation отражает одновременно новые запросы, календарный период, дополнительное обучение на validation и усреднение seeds; интерпретация только как temporal drift была бы некорректна.

9. Равный бюджет: importance и случайный выбор окон

Исходный поиск признаков не сравнивался со случайным поиском при том же бюджете. Для устранения этого пробела после исходной итоговой оценки выполнен отдельный development-контроль. До первого нового обучения зафиксированы четыре независимых равномерных набора из девяти групп, размеры 1/2/3/5, RNG seed 20261025. Выбор без возвращения внутри набора не запрещает совпадения между пробами. Первый набор случайно совпал с importance-k1; он не перерисовывался, а его повторное обучение точно воспроизвело метрики и число деревьев.

Обе процедуры сохраняют 181 manual-признак и получают CatBoost depth=7, L2=15, seed17, 2000 непрерывно обученных деревьев. Полный validation NDCG оценивается каждые 50 деревьев; выбираются лучший префикс деревьев и лучший из четырёх наборов по равному среднему двух недель. Сохранённая обучающая выборка, полные validation-кандидаты и знаменатели совпадают; новых negatives и правильных кандидатов не добавляли. Importance-результаты взяты из исходных четырёх обучений.

Таблица 6. Development-контроль: четыре обучения на наборах окон для каждой процедуры; не новая итоговая выборка.

k	Importance: дни	Random: дни	NDCG I	NDCG R	R - I
1	3	3	0.161732	0.161732	+0.000000
2	3,2	3,21	0.161906	0.162956	+0.001050
3	3,2,5	5,14,21	0.164286	0.162187	-0.002100
5	3,2,5,45,60	2,5,10,21,60	0.163148	0.162212	-0.000936

Два исходных обучения CB со всеми окнами, из которых выбраны общие параметры и importance-порядок, стоят 881.62 с и являются общим precompute. Четыре обучения на наборах окон стоят 1212.20 с у importance и 1167.97 с у random; вместе с общим precompute - 2093.81 и 2049.58 с. Равенство числа обучений и лимита деревьев не означает равенства затраченного времени.

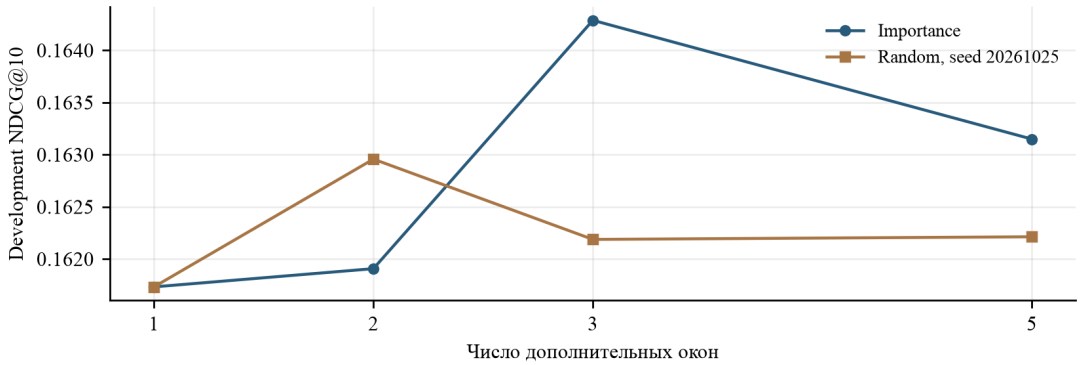


Рисунок 1. Один заранее заданный random-search probe. Точки выбраны по tree-prefix на тех же development-неделях; интервалы не оценивались.

Лучший random-набор [3,21] даёт 0.162956 против 0.164286 у importance [3,2,5]. Разности random - importance по неделям: -0.000437, -0.002224. Это одна реализация ограниченного поиска, а не оценка его дисперсии или формальная проверка превосходства. В random-k5 порядок блоков колонок отличается от importance-сериализации и может влиять на fixed-seed CB. Наборы и бюджет после результатов не расширялись; новое итоговое обучение random на ранее открытом KION-тесте не выполнялось.

10. Итоговая оценка на новых пользователях

Таблица 7. Confirmation: 4558 warm users, 4268657 candidate pairs, общий candidate recall 0.794603. Последняя колонка - число различных рекомендованных объектов.

Система	NDCG@10	Recall@10	MAP@10	Объектов в top10
Ручная база	0.163488	0.240308	0.113644	747
Все окна	0.164175	0.242500	0.113891	723
Выбранные окна	0.165822	0.243476	0.115651	756
Представления	0.148384	0.219264	0.102612	719
Окна + представления	0.165344	0.241842	0.115614	716
Представления + якоря	0.150709	0.220747	0.105121	625
Окна + якоря	0.162365	0.240964	0.112343	706
RRF генераторов	0.144299	0.211557	0.100618	565
Исходная смесь KION	0.165000	0.241966	0.115017	736
Популярность	0.127922	0.191326	0.088808	26

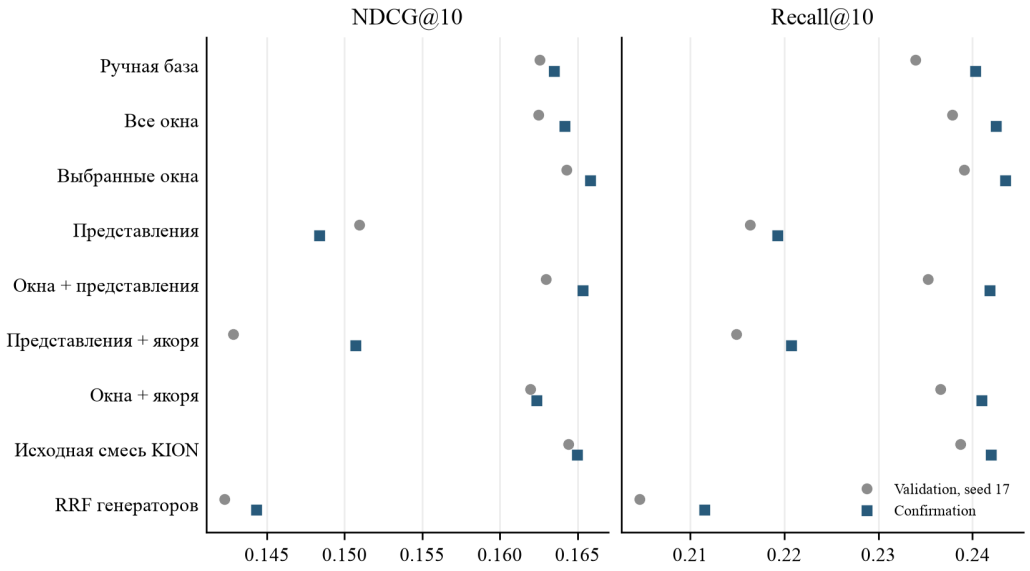


Рисунок 2. Development и confirmation показаны отдельно. Соединять эти точки как оценку одного и того же fit некорректно.

Пропущенные positives, включая cold items, остаются в знаменателях. Основные результаты условны на future-positive warm users, поэтому их нельзя переносить на всех зарегистрированных пользователей. Популярность и generator RRF оцениваются на тех же запросах и кандидатах; они отделяют пользу сложного ranking от самого качества общего retrieval.

NDCG и Recall могут дать разные направления изменения: первый показатель чувствителен к ранним позициям и индивидуальному ideal DCG, второй считает долю всех истинных ответов среди десяти рекомендаций. Ни один из них не измеряет длительность просмотра, разнообразие потребления или причинное удовлетворение пользователя.

11. Парные различия и статистическая интерпретация

Для пользователя u определяется d_u = $metric_{challenger,u}$ - $metric_{reference,u}$. Bootstrap ресэмплирует пользователей целиком с возвращением и усредняет d; из 2000 повторов берутся percentile-границы 2.5% и 97.5%, seed 2026. Это парная процедура: обе системы оцениваются на одних и тех же user queries.

Таблица 8. Основные объявленные сравнения. Дельты в единицах метрик, не в процентах.

Сравнение	**ΔNDCG [95% интервал]**	**ΔRecall [95% интервал]**
Выбранные окна - ручная база	+0.002334 [+0.000795; +0.004025]	+0.003168 [+0.000399; +0.006054]
Исходная смесь KION - ручная база	+0.001512 [-0.000040; +0.003091]	+0.001659 [-0.001197; +0.004506]
Ручная база - popularity	+0.035565 [+0.030349; +0.040730]	+0.048982 [+0.041905; +0.056564]

Таблица 9. Дополнительные пары определены до итоговой оценки и не участвуют в выборе primary.

Диагностическая пара	**ΔNDCG [95% интервал]**	**ΔRecall [95% интервал]**
Представления - Ручная база	-0.015104 [-0.018683; -0.011767]	-0.021043 [-0.027151; -0.015006]
Представления + якоря - Представления	+0.002325 [+0.000309; +0.004397]	+0.001483 [-0.001352; +0.004484]
Окна + якоря - Окна + представления	-0.002979 [-0.004877; -0.001131]	-0.000879 [-0.003965; +0.002050]

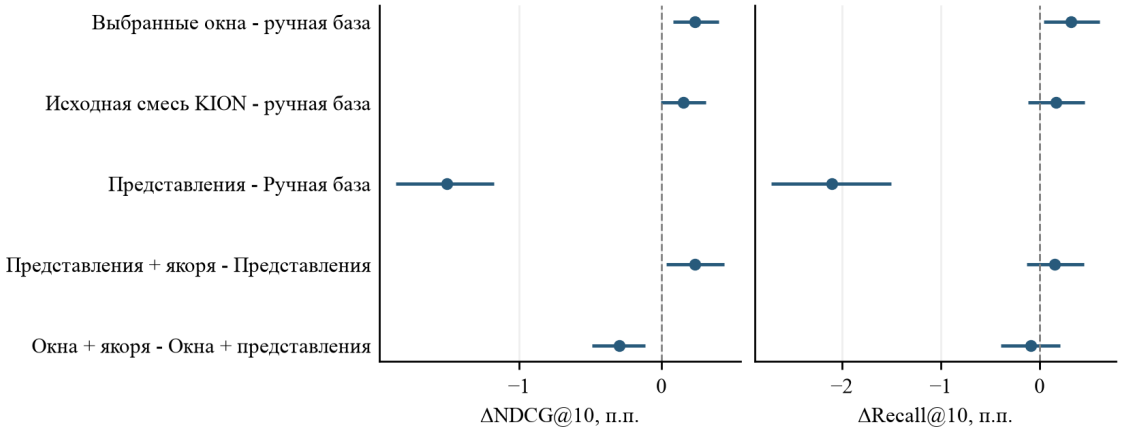


Рисунок 3. Сохранённые парные 95% интервалы; горизонтальная шкала в процентных пунктах. Интервалы маргинальные, без multiplicity correction.

Для primary относительно manual интервал включает ноль. Это описательная оценка фиксированных систем на данной пользовательской выборке. Интервал, пересекающий ноль, не доказывает равенство или отсутствие практически значимого ущерба. Граница non-inferiority заранее не задавалась.

Bootstrap не переобучает модели и не меняет неделю, каталог или retrieval. Он не учитывает вариативность HPO и будущих периодов. Много ветвей, метрик и диагностических пар увеличивают риск выборочного прочтения результатов; здесь не проводится поправка на множественность и не объявляется набор независимых confirmatory-тестов.

12. Ресурсы, компактность и cold fallback

Таблица 10. Суммарная стоимость фиксированного refit всех seeds каждой ветви, без общего retrieval.

Ветка	Seeds	Refit, с	Модели, MB
Ручная база	3	1082.8	919.1
Все окна	3	1096.8	877.8
Выбранные окна	3	986.1	903.6
Представления	3	673.3	1473.2
Окна + представления	3	1515.2	842.8
Представления + якоря	3	627.5	968.0
Окна + якоря	3	992.2	649.2

Development search V4 занял 5188.5 с; дополнительный поиск anchor-ветвей - 1814.3 с. Полный итоговый scoring всех диагностических ветвей с загрузкой моделей и projected I/O - 297.1 с; собственно преобразование признаков и native prediction - 271.9 с. Эти стадии указаны раздельно; отсутствующие замеры не заменяются нулём.

Измеренный peak RSS development/final составляет 5.90 / 6.13 GB. Это пики отдельных процессов, а не сумма и не изолированный serving benchmark.

Расходы общих CF-моделей и построения snapshots разделяются между ветвями. Исходное fit-время кешированного генератора не является новым wall time каждого использования. Время snapshot включает retrieval, построение признаков, I/O и возможный fit/чтение кеша; ниже отдельный benchmark выделяет feature-only и warm-request стадии. Поэтому суммы различных сохранённых длительностей не интерпретируются как точное end-to-end время.

Таблица 11. Ресурсы исходной смеси и базы. Общие retrieval-модели исключены; время запроса измерено отдельно.

Система	GBDT-моделей	Refit, с	Модели, MB
Ручная база	3	1082.8	919.1
Выбранная смесь	6	2082.9	1781.4

Таблица 12. Все будущие активные пользователи; 2324 cold users получают общий fallback.

Система	Warm + cold users	NDCG@10	Recall@10
Ручная база	6882	0.190321	0.279990
Выбранные окна	6882	0.191867	0.282088
Представления	6882	0.180317	0.266052
Исходная смесь KION	6882	0.191322	0.281088
Популярность	6882	0.166765	0.247549

Warm+cold и warm оценивают разные наборы запросов; более высокое среднее не означает улучшения на прежних warm users. Cold-only запрос не требует GBDT. Само уменьшение входной размерности ещё не доказывает ускорения: важно исключить построение неиспользуемых блоков и сравнивать одинаковые границы измерения. Именно это делает следующий benchmark.

13. Измерение стоимости запроса

Из prefix-пользователей равномерно выбраны 128 ID без фильтра по будущей активности (seed2026). Все три системы получают этих же пользователей и 124931 candidate pairs. Prefix-fit и GBDT не переобучаются. Один warmup и три измеряемых повтора выполняются с четырьмя GBDT-потоками и одним BLAS-потоком. Величины ниже - секунды на batch из 128 пользователей; это не индивидуальная latency и не production SLA.

Selective store строит только требуемые окна и колонки: 181 у manual, 223 у выбранных окон и 307 у исходной смеси. Значения всех требуемых признаков точно совпали с полным 398-колоночным store. Неиспользуемые latent/anchor-блоки не строятся. Feature-only измеряет build на готовых кандидатах; full warm request включает retrieval, selective build, prediction загруженных моделей и выдачу top10.

Таблица 13. Среднее [min;max] трёх повторов. Prefix aggregate-store constructor указан отдельно от запросов.

Система	F	Моделей	Build, с	Warm request, с	Store startup, с
Ручная база	181	3	0.336 [0.334; 0.338]	2.323 [2.311; 2.335]	6.541
Выбранные окна	223	3	0.362 [0.360; 0.365]	2.361 [2.345; 2.390]	6.543
Исходная смесь KION	307	6	0.422 [0.420; 0.424]	3.436 [3.424; 3.451]	7.280

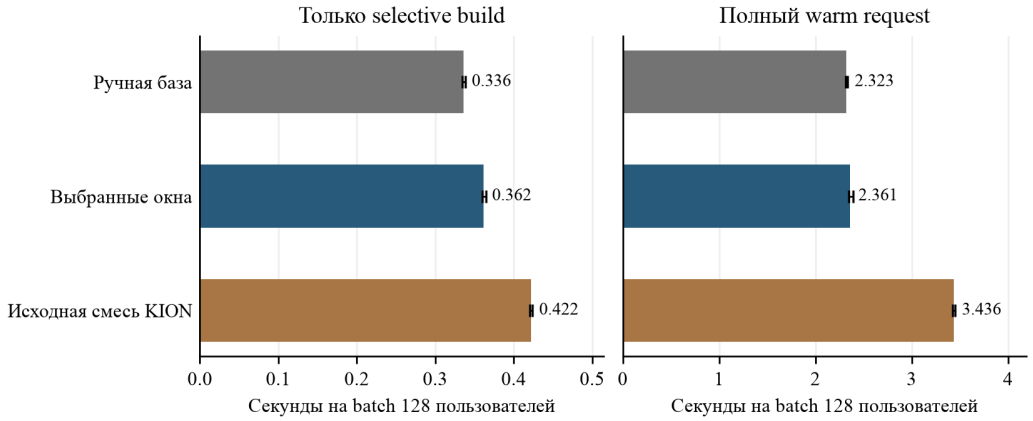


Рисунок 4. Одинаковый batch и selective feature construction. Штрихи показывают диапазон трёх локальных повторов, не доверительный интервал.

Выбранные окна требуют 1.016× времени warm-запроса manual; шесть моделей исходной смеси - 1.479×. Это конкретный quality-cost результат этого стенда. Он не доказывает пропорциональной зависимости latency от числа признаков или моделей.

Что вынесено за границу warm request

Общая загрузка prefix-index: 0.277 с; дополнительных генераторов: 0.303 с; чтение raw и prefix-фильтр: 0.533 с. Первичное построение кандидатов для feature-only замера: 1.024 с. Aggregate-store startup занимает 6.54-7.28 с и может амортизироваться между запросами.

Первое / повторное чтение ансамбля в данном процессе: manual 0.213 / 0.082 с; selected 0.146 / 0.058 с; смесь 0.400 / 0.281 с. OS cache не сбрасывался: это наблюдаемое process-load I/O, а не физически холодный диск. Прогрев моделей, глобальный prefix-fit и запуск приложения не скрываются внутри warm-цифр.

14. Внешняя проверка: Yambda и новые периоды

Yambda-5B - открытые музыкальные взаимодействия с разделением organic и recommendation-driven событий [11]. Для этой работы использована публичная sequential 50M-выборка [12], а не весь многомиллиардный набор. В отличие от KION, сохранённые последовательности позволяют считать повторные прослушивания в каждом прошлом окне. Проверяется перенос идеи временной грамматики; официальный Yambda benchmark не воспроизводится.

До чтения новых Task1-целей зафиксированы 4000 пользователей вне Task2-когорты: 2500 train, 500 validation, 1000 test. Исходные данные уже были известны по другой задаче; это не заявление о глобально невиденном raw-наборе. Выбранные ниже недели предшествуют периодам quality-оценки Task2, а его пользователи исключены. Когорты выбраны без требования будущей активности. Все raw listen histories выбранных пользователей сохраняются, включая organic, повторы и редкие треки вне рабочего каталога.

Для этих пользователей сохранены 16 859 106 raw listens без усечения длинных историй. В каждом срезе из них используется только строгий прошлый префикс.

$$d = timestamp / 86400;\ H(d) = \{e:\ timestamp_e < 86400\ d\}.$$

Таблица 14. Предварительно заданные относительные интервалы. Дни не являются Unix- или календарными датами.

Роль	Начало прогноза, относительный день	Семидневные цели	Когорта
Train	133; 140	[133,140); [140,147)	2500
Validation	147; 154	[147,154); [154,161)	500
Final	161; 168; 175	[161,168); [168,175); [175,182)	1000

Цель и доступный каталог

$$Y_{u,d} = unique\ \{\ item_e:\ d \le t_e/86400 < d+7,\ event_type = listen,\ is_organic = 0\ \}.$$

Целью являются все записанные recommendation-driven listen-события, включая нулевой played ratio. Это наблюдаемый факт взаимодействия, не satisfaction и не официальный Listen+ с порогом свыше 50% [12]. Никакой KION-фильтр duration≥300 к музыке не переносится. Ранее прослушанный трек остаётся допустимой рекомендацией и будущим positive; seen exclusion здесь намеренно отсутствует.

Каталог - top10000 по числу прошлых listens всех выбранных пользователей строго до дня133, с разрешением равенств по track ID. Затем ID каталога фиксируются. Это трансдуктивное использование прошлых историй всех когорт, а не будущих меток. Истинные ответы вне каталога не удаляются из IDCG/Recall. Static artist mapping сводится к минимальному artist ID объекта; его историческая доступность неизвестна.

Главная популяция - все будущие активные пользователи, в том числе без истории, с единым popularity fallback. No-positive queries не получают искусственный нулевой NDCG: они учитываются в размерах когорт, но метрика интереса для них не определена. Warm-оценка показывается отдельно. Пользователь с rare-only прошлым остаётся warm, хотя CF-каталог может не содержать его истории.

15. Yambda: сильная база и симметричный поиск

Общий retrieval объединяет popularity500 за последние 30 дней, BM25 ItemKNN200 (K1=1.2, B=.8, topK=200) и ALS100 (32 фактора, α=10, regularization=.5, десять итераций). CF использует бинарный user-track префикс на фиксированном каталоге. Объединение не дополняется целевыми треками. Count-признаки сохраняют число повторных прослушиваний, включая события вне каталога там, где определяется история пользователя или artist.

Таблица 15. Manual уже содержит статистики четырёх масштабов времени; automatic добавляет окна, а не создаёт отсутствующую базу.

Ручная группа	Содержание
Retrieval и категории	Scores/ranks трёх источников, track/artist ID, последний raw track.
История и recency	Давность пользователя/item/пары, span истории, число distinct raw tracks, cold flag.
Окна 1/7/30/all	User/item/pair count и доли; artist affinity и её доля.
Дополнительная грамматика	Те же 8 агрегатов в окнах 2/3/5/10/14/21/45/60/90.

Для обучения каждого query равномерно сохраняются максимум 20 найденных positives и min(3p,25,z) negatives без возвращения, где p - число сохранённых positives, z - число доступных истинных нулевых кандидатов. Остальные positives исключаются из обучения, а не превращаются в negatives. Все ветви получают ту же выборку; запросы без найденных positives пропускаются только при обучении. Validation и final используют полные общие candidate lists и полный истинный знаменатель.

Бюджет и замораживание выбора

Параметры перенесены без нового HPO: CB depth7/L2=15, learning rate .03, seed17, 2000 непрерывных деревьев, выбор prefix каждые50 по равному среднему двух недель. Общие обучения manual и всех окон дают baseline и importance-порядок обученной модели. Importance проверяет его префиксы 1/2/3/5, random - четыре заранее заданных независимых набора тех же размеров, seed20261026. В обеих ветвях выбранные блоки колонок сериализуются в одном каноническом порядке дней: различается состав признаков.

Оба автоматических варианта обязаны выбрать непустой набор k из {1,2,3,5}; manual не является их fallback. Это диагностическое сравнение заранее заданных процедур, а не правило, обязывающее применять окна при худшем validation-результате.

All-window модель сама выбирает tree-prefix на этих же двух validation-неделях. Поэтому полученный из её train-fitted importance порядок не является процедурой, полностью независимой от validation. Эта общая стадия и её стоимость указаны явно.

После development для каждого из трёх фиксированных вариантов manual/importance/random выбираются набор окон и число деревьев; затем все переобучаются с seeds17/42/73 на train и одинаково сэмплированной validation. На трёх final-неделях веса GBDT, наборы окон и деревья не меняются. Глобальный CF и признаки обновляются перед каждой неделей только по её прошлому. Победитель по final не выбирается.

Заранее заданный основной контраст

$$\Delta = (1/3)\,\Sigma_{w \text{ in } \{161,168,175\}} \left[\text{mean}_{u \text{ in } A_w} NDCG_{importance,u,w} - \text{mean}_{u \text{ in } A_w} NDCG_{manual,u,w}\right].$$

Основной контраст - importance minus manual на all-active; random-контрасты, Recall и отдельные недели вторичны. Среднее берётся по трём недельным macro, а не по доступным неделям каждого пользователя. Для неопределённости используется общий user-cluster bootstrap по active-user union; его единицы и границы приведены вместе с интервалами.

16. Yambda: результаты по неделям

На development NDCG@10: manual 0.216205, importance 0.212957, random 0.212386. Практическое правило с возможностью пустого набора могло бы оставить manual уже на validation. Здесь три варианта сохраняются ради диагностической проверки; добавление окон вопреки этой оценке не рекомендуется.

Таблица 16. Полные знаменатели future-positive; все активные пользователи и общий cold fallback. По три seed-модели на вариант.

День	Manual	Importance	Random	I - M	I - R
161	0.179482	0.178813	0.180179	-0.000669	-0.001366
168	0.152261	0.149447	0.149458	-0.002814	-0.000011
175	0.164831	0.170494	0.172001	+0.005663	-0.001508

Таблица 17. Равное среднее трёх недельных user-macro. Это не pooled среднее по всем query-строкам.

Система	NDCG@10	Recall@10	Candidate recall
Manual	0.165525	0.019813	0.211307
Importance	0.166251	0.020039	0.211307
Random	0.167213	0.019600	0.211307

Random имеет более высокий точечный NDCG (0.167213), но победитель по final не выбирается. Общий candidate recall 0.211307 показывает сильное ограничение retrieval: большинство истинных треков не попадает в union. Абсолютные метрики нельзя напрямую сопоставлять с KION, где отличаются цель, повторы и каталог.

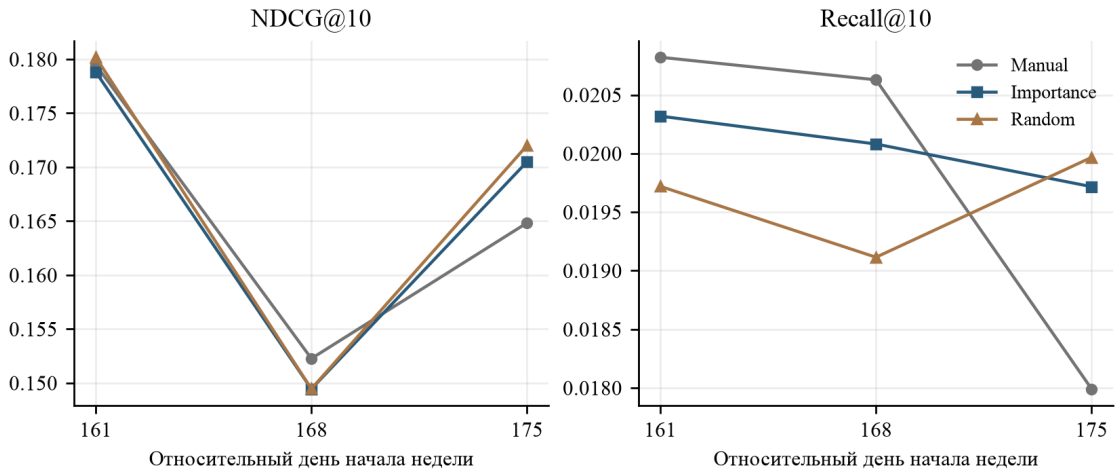


Рисунок 5. Каждая неделя показана отдельно. Системы используют обновляемый прошлый префикс; наборы окон и GBDT не меняются.

Importance: выбранные окна [90, 60], 63 признаков, 1900 деревьев в одной seed-модели; development NDCG 0.212957.

Random: выбранные окна [2, 10, 21, 60, 90], 87 признаков, 1950 деревьев в одной seed-модели; development NDCG 0.212386.

Число будущих активных пользователей по неделям: 387, 401, 404; без будущих positives: 613, 599, 596; cold active: 3, 11, 6. Пропущенные retrieval/catalog positives остаются ошибками системы, а не исключаются из оценки.

17. Yambda: неопределённость, устойчивость и стоимость

Bootstrap ресэмплирует union пользователей с positives хотя бы в одной из трёх final-недель, а не все 1000 raw test ID. Один multiplicity пользователя применяется во всех неделях; в каждой реплике сначала вычисляется weighted macro внутри недели, затем равное среднее трёх недель. 2000 повторов, seed2026. Это сохраняет повторение пользователей и пропуски отдельных недель; никогда не активные не получают искусственную метрику.

Таблица 18. Clustered user-bootstrap с общими multiplicities во всех неделях; маргинальные описательные интервалы.

Контраст	ΔNDCG [95% интервал]	ΔRecall [95% интервал]
Importance - manual (основной)	+0.000726 [-0.002946; +0.004308]	+0.000225 [-0.000808; +0.001480]
Random - manual	+0.001688 [-0.002348; +0.005754]	-0.000213 [-0.001456; +0.001165]
Importance - random	-0.000961 [-0.004767; +0.002499]	+0.000438 [-0.000462; +0.001341]

Основной контраст importance - manual: +0.000726 [-0.002946; +0.004308], интервал включает ноль. Недельные дельты: -0.000669, -0.002814, +0.005663; положительны 1 из трёх, отрицательны 2. Направление различается между неделями. Среднее и интервал относятся к этим фиксированным периодам, а не к распределению качества на всех будущих неделях.

В bootstrap 489 уникальных пользователей с positives хотя бы в одной из трёх недель и 1192 user-week queries. Пропуски отдельных недель сохраняются; один пользователь не превращается в независимые наблюдения.

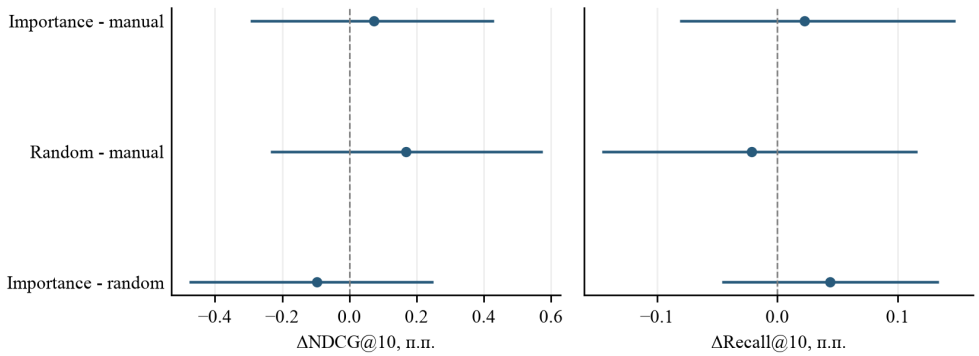


Рисунок 6. Три заранее заданных контраста. Отрицательная шкала означает преимущество reference; итоговый вариант по этим данным не выбирается.

Таблица 19. Общие development-обучения manual/всех окон: 78.7 с, отдельно от четырёх обучений на наборах каждой процедуры.

Вариант	Поиск окон, с	Refit 3 seeds, с	Модели, MB
manual	0.0	111.1	555.3
importance	147.3	114.9	514.2
random	148.1	129.9	472.2

Эта внешняя проверка меняет домен, доступность полной истории и цель, а не просто пользователей KION. Она не является причинным A/B-тестом или оценкой всех будущих недель. Три периода фиксированы; bootstrap учитывает повторение пользователей, но не ресэмплирует обучение, search RNG, платформу или будущую календарную среду. Одного random seed недостаточно для вывода о распределении эффективности random search.

18. Обсуждение и границы вывода

Исходная смесь KION даёт итоговую разность NDCG@10 +0.0015 относительно manual. Она объединяет две ветви, каждая сохраняет ручную базу. Её 95% интервал включает ноль; шесть моделей против трёх увеличивают измеренную стоимость запроса. Это сохранённый исходный primary-результат, а не рекомендация платить за доказанный прирост. Новый контроль и внешняя проверка не меняют её после теста.

Для конструкции representations разность относительно manual равна -0.0151 NDCG@10. Это отдельная проверка замены части агрегатов при сохранении общих генераторов, категорий и history similarity. Её нельзя смешивать с результатом auto_selected или объявлять результатом всех возможных обучаемых представлений. Практическая приемлемость меньшего набора признаков зависит от допустимой потери качества, которая заранее не задавалась.

Ветка с 58 входами исключает явные оконные и трендовые агрегаты; сжатие истории через ALS не обязано восстанавливать ту же информацию. Это правдоподобное объяснение потери качества, а не изолированный причинный тест. Меньше признаков также не означает меньше модель: ensemble representations занимает 1473.2 MB против 919.1 MB у manual. Глубина и число деревьев различаются. Anchors улучшают точечный результат этой компактной конструкции, но её NDCG остаётся ниже manual; прямой отдельный anchor-versus-manual интервал здесь не заявляется.

Anchor-конструкция имеет понятную инвариантность и ограниченную размерность, но математическая корректность не гарантирует статистической полезности. Семантика фиксированного объекта сохраняется между неделями, тогда как его факторы и окружающая геометрия могут меняться. В исходных train-факторах span якорей не охватывает всё пространство; отрицательные или нестабильные matched-дельты не следует скрывать за общим качеством наиболее сильной смеси.

Ограничения валидности

Временная переносимость. Новые пользователи оцениваются на знакомой календарной неделе KION. Внешняя Yambda-проверка добавляет три заранее заданных периода другого домена без выбора по их результатам. Она расширяет проверку, но не делает эти три периода случайной выборкой всех будущих недель.

Наблюдаемость истории. Последняя дата пары скрывает ранние повторы, если её последний просмотр лежит в будущем. Статические metadata не имеют истории доступности, а ingestion delay неизвестен. Законность прошлых aggregate-полей не устраняет эти ограничения.

Условная популяция. Warm future-positive denominator отличается от всей пользовательской базы; неявные negatives и positive-containing train queries также задают конкретную выборку. Исследование не измеряет удовлетворённость, diversity, возвращаемость или причинное действие рекомендаций.

Бюджет и множественность. В исходном KION-поиске число моделей не полностью выровнено. Feature selection, HPO и смесь повторно используют две недели; bootstrap условен на выбранных системах. Дополнительный четырёх-fit random control и симметричная Yambda-процедура закрывают конкретный пробел бюджета, а не устраняют search variance. Утверждения о non-inferiority или универсальном превосходстве не следуют.

Ресурсы. Локальное wall time зависит от аппаратуры, конкурирующей нагрузки, кеша и памяти. Общий diagnostic scoring 21 модели не является latency production primary из шести моделей. Отдельный selective-serving замер сравнивает три фиксированные ветви на одном batch; заранее заданный business quality-cost критерий по-прежнему отсутствует.

19. Выводы и масштабирование

Выбранные окна относительно ручной базы: ΔNDCG@10 +0.002334, 95% интервал [+0.000795; +0.004025]; интервал полностью выше нуля. Это дополнение сильной ручной базы, ограниченное заранее заданными отношениями, агрегатами и девятью дополнительными окнами; произвольного поиска формул нет. Период KION был знаком, поэтому одного user-disjoint результата недостаточно для вывода о временной переносимости.

При условном бюджете четырёх обучений importance даёт development NDCG 0.164286 против 0.162956 у random. Это одна seed-fixed проба, выполненная после исходного теста; она не устанавливает распределение выигрыша importance и не используется для смены KION-системы.

На Yambda, с полной слушательской историей, сильной manual-базой и тремя фиксированными вариантами по три seeds, основной контраст importance - manual равен +0.000726 [-0.002946; +0.004308]. Интервал включает ноль. Это равное среднее трёх недель; две недельные разности отрицательны, одна положительна. Устойчивое внешнее преимущество не установлено; интервал условен на active-user union и этих периодах. Manual уже был лучше обоих обязательных непустых наборов на validation, поэтому диагностическая оценка не является рекомендацией добавлять окна вопреки этому сигналу.

Представления относительно ручной базы: ΔNDCG@10 -0.015104, 95% интервал [-0.018683; -0.011767]; интервал полностью ниже нуля. Данный вариант заменяет часть агрегатов, но сохраняет обученные retrieval-сигналы, категории и history similarity. Результат не является выводом обо всех representation-моделях.

Представления + якоря относительно представлений: ΔNDCG@10 +0.002325, 95% интервал [+0.000309; +0.004397]; интервал полностью выше нуля. Окна + якоря относительно окон с представлениями: ΔNDCG@10 -0.002979, 95% интервал [-0.004877; -0.001131]; интервал полностью ниже нуля.

Эти diagnostic-интервалы описательные. Геометрическая инвариантность якорей не означает универсального улучшения рекомендаций; независимо выбранное число деревьев и бюджеты поиска ограничивают причинное прочтение дельт. Пересечение интервала с нулём не устанавливает равенство или non-inferiority.

Dense factor retrieval для batch B и каталога I требует памяти O(BI) и вычислений O(BId) при размерности d. Для EASE память обучения $O(I_{EASE}^2)$, решение $O(I_{EASE}^3)$, здесь I_{EASE}=5000. Материализация признаков имеет объём O(|C|F), рабочий batch - $O(C_{batch}F)$ = O(BKF), где B - число пользователей, K - среднее число кандидатов на пользователя. Почти миллион пользователей при каталоге около 15 тысяч объектов не доказывает масштабируемость на миллионы объектов и миллиарды событий; ANN retrieval и offline feature cache потребуют отдельного исследования компромисса качества и стоимости.

Измеренное время warm-запроса на одинаковых 128 пользователях: manual 2.323 с, выбранные окна 2.361 с, исходная смесь 3.436 с. Startup и process-load I/O измерены отдельно. У смеси KION интервал качества включает ноль при большей цене; её нельзя преподносить как установленную практическую пользу ансамбля.

Выбор окон, замена агрегатов представлениями и ансамблирование оказались разными исследовательскими вопросами. Содержательный итог включает отрицательные representation и нестабильные геометрические результаты, равный бюджет простого random-контроля и внешнюю проверку на фиксированных периодах. Они поддерживают ограниченные выводы о конкретной системе; переносимость и эксплуатационная ценность требуют собственных критериев.

20. Литература и первичные реализации

[1] Т-Банк, 2019. Разбор решения Rekko Challenge: многогенераторные рекомендации и бустинг.
https://habr.com/ru/companies/tbank/articles/454818/

[2] Petrov A., Safilo I., Tikhonovich D., Ignatov D., 2022. MTS Kion Implicit Contextualised Sequential Dataset for Movie Recommendation.
https://arxiv.org/abs/2209.00325

[3] Тихонович Д. Открытое решение ODS MTS RecSys Challenge: ItemKNN, временные признаки и CatBoost.
https://github.com/blondered/ods_MTS_RecSys_Challenge_solution

[4] Petrov A. KION solution: featurizer, многогенераторная схема и LambdaRank.
https://github.com/asash/bert4rec_repro

[5] RecTools. Benchmark iALS with user/item features: KION weighting and metadata recipe.
https://rectools.readthedocs.io/en/latest/examples/5_benchmark_iALS_with_features.html

[6] Kula M., 2015. Metadata Embeddings for User and Item Cold-start Recommendations.
https://arxiv.org/abs/1507.08439

[7] Steck H., 2019. Embarrassingly Shallow Autoencoders for Sparse Data.
https://arxiv.org/abs/1905.03375

[8] Qi D., Zheng W., Wang J., 2024. FeatAug: Automatic Feature Augmentation From One-to-Many Relationship Tables.
https://arxiv.org/abs/2403.06367

[9] Featuretools. Handling Time: cutoff-aware feature calculations and training windows.
https://docs.featuretools.com/en/stable/getting_started/handling_time.html

[10] Melchiorre A. B. et al., RecSys 2022. ProtoMF: Prototype-based Matrix Factorization for Effective and Explainable Recommendations.
https://hcai.at/publications/2022_protomf/

[11] Ploshkin A. et al., 2025. Yambda-5B - A Large-Scale Multi-modal Dataset for Ranking And Retrieval.
https://arxiv.org/abs/2505.22238

[12] Yandex. Official Yambda dataset card: event formats, organic flag and Listen+ definition.
https://huggingface.co/datasets/yandex/yambda

Материалы исследования

Числа таблиц и рисунков формируются из results/experiment.json, random_search.json, serving_benchmark.json и yambda.json. Это сохранённые агрегированные метрики, выбранные модели, парные интервалы, ресурсы и диагностика кандидатов/якорей. Статья и графики не выполняют обучение, подбор моделей или новое вычисление рекомендаций. Дельты и суммы ресурсов являются арифметикой уже сохранённых агрегатов. Индивидуальные истории и списки пользователей для чтения статьи не требуются.

Исходные локальные измерения выполнены на macOS (Darwin), архитектура arm64: Python 3.11.15, 10 логических CPU, 16 GiB оперативной памяти. Для GBDT использованы 4 потока, для collaborative-моделей и BLAS - 1 поток. Это описание исследовательского окружения, а не оценка throughput выделенного production-сервера.

Датировка исходной выгрузки соответствует использованным CSV 2021 года, а не календарной опечатке в README набора. Наблюдаемые свойства benchmark и преобразования в этой работе отделены от результатов исходных авторов. Опубликованные бизнес-эффекты и метрики конкурсных решений не переносятся на полученные здесь оценки.